
```
<!DOCTYPE html> <html lang="en-US"> <head> <meta
charset="utf-8"> <meta name="viewport" content="width=device-
width,initial-scale=1"> <title>SUSTech Open Source Mirrors</title>
<meta name="generator" content="VuePress 1.9.10"> <script
async="true" src="https://www.googletagmanager.com/gtag/js?id=G-
0KD226TRZ5"></script> <script> window.dataLayer = window.dataLayer
|| []; function gtag()dataLayer.push(arguments); gtag('js', new
Date());
```

```
gtag('config', 'G-0KD226TRZ5'); </script> <meta name="description"
content="Open source mirror site supported by SUSTech Cen-
ter for Computational Science and Engineering amp; SUSTech
Computer Research Association">
```

```
<link rel="preload" href="/assets/css/0.styles.c1cef7d5.css"
as="style"><link rel="preload" href="/assets/js/app.3e271561.js"
as="script"><link rel="preload" href="/assets/js/9.07c9b3e1.js"
as="script"><link rel="prefetch" href="/assets/js/1.d2a9cd4b.js"><link
rel="prefetch" href="/assets/js/100.384b8c08.js"><link rel="prefetch"
href="/assets/js/101.8a79aa38.js"><link rel="prefetch" href="/assets/js/102.5bb0ff
rel="prefetch" href="/assets/js/103.0a0ea79e.js"><link rel="prefetch"
href="/assets/js/104.affce49f.js"><link rel="prefetch" href="/assets/js/13.32573da7
rel="prefetch" href="/assets/js/14.102e5887.js"><link rel="prefetch"
href="/assets/js/15.71b72ed0.js"><link rel="prefetch" href="/assets/js/16.4de6938
rel="prefetch" href="/assets/js/17.24250230.js"><link rel="prefetch"
href="/assets/js/18.17a1a48d.js"><link rel="prefetch" href="/assets/js/19.5b3159a
rel="prefetch" href="/assets/js/2.4e46c9ab.js"><link rel="prefetch"
href="/assets/js/20.d83afba7.js"><link rel="prefetch" href="/assets/js/21.b0e50066
rel="prefetch" href="/assets/js/22.4b2938d0.js"><link rel="prefetch"
href="/assets/js/23.034c58a7.js"><link rel="prefetch" href="/assets/js/24.9b28e5f4
rel="prefetch" href="/assets/js/25.f05f9dd5.js"><link rel="prefetch"
href="/assets/js/26.b5761c31.js"><link rel="prefetch" href="/assets/js/27.a2452ab
rel="prefetch" href="/assets/js/28.0cf887e7.js"><link rel="prefetch"
href="/assets/js/29.752fb5c6.js"><link rel="prefetch" href="/assets/js/3.b2afe49f.js
rel="prefetch" href="/assets/js/30.71126ae9.js"><link rel="prefetch"
href="/assets/js/31.2a4e21ff.js"><link rel="prefetch" href="/assets/js/32.2379d268
rel="prefetch" href="/assets/js/33.a907315c.js"><link rel="prefetch"
```

href="/assets/js/59.ff8e3637.js"><link rel="prefetch" href="/assets/js/6.9a41f9ad.js">
rel="prefetch" href="/assets/js/60.3585c01d.js"><link rel="prefetch"
href="/assets/js/61.08b350f6.js"><link rel="prefetch" href="/assets/js/62.58d3d9e8.js"
rel="prefetch" href="/assets/js/63.a6b7efb6.js"><link rel="prefetch"
href="/assets/js/64.38112fd3.js"><link rel="prefetch" href="/assets/js/65.3b917f6e.js"
rel="prefetch" href="/assets/js/66.acdf1cb9.js"><link rel="prefetch"
href="/assets/js/67.b1e46ff8.js"><link rel="prefetch" href="/assets/js/68.96824346.js"
rel="prefetch" href="/assets/js/69.ad1642ba.js"><link rel="prefetch"
href="/assets/js/7.8fa26da8.js"><link rel="prefetch" href="/assets/js/70.9bf5d506.js"
rel="prefetch" href="/assets/js/71.8c4c860b.js"><link rel="prefetch"
href="/assets/js/72.608c9cd0.js"><link rel="prefetch" href="/assets/js/73.28ee4dcc.js"
rel="prefetch" href="/assets/js/74.3aaefcce.js"><link rel="prefetch"
href="/assets/js/75.a3021d7b.js"><link rel="prefetch" href="/assets/js/76.18a038b8.js"
rel="prefetch" href="/assets/js/77.6943b45f.js"><link rel="prefetch"
href="/assets/js/78.2d13eaf0.js"><link rel="prefetch" href="/assets/js/79.9167eb5a.js"
rel="prefetch" href="/assets/js/8.c6616b08.js"><link rel="prefetch"
href="/assets/js/80.02308484.js"><link rel="prefetch" href="/assets/js/81.638c89a8.js"
rel="prefetch" href="/assets/js/82.a9843716.js"><link rel="prefetch"
href="/assets/js/83.14fec183.js"><link rel="prefetch" href="/assets/js/84.f5ff0b1e.js"
rel="prefetch" href="/assets/js/85.e7e0dd48.js"><link rel="prefetch"
href="/assets/js/86.2934a579.js"><link rel="prefetch" href="/assets/js/87.7990bad1.js"
rel="prefetch" href="/assets/js/88.1983db58.js"><link rel="prefetch"
href="/assets/js/89.28eeb643.js"><link rel="prefetch" href="/assets/js/90.ece981e8.js"
rel="prefetch" href="/assets/js/91.4f71f83c.js"><link rel="prefetch"
href="/assets/js/92.f14fd882.js"><link rel="prefetch" href="/assets/js/93.97366284.js"
rel="prefetch" href="/assets/js/94.2153521e.js"><link rel="prefetch"
href="/assets/js/95.0f005ba2.js"><link rel="prefetch" href="/assets/js/96.7f5674e8.js"
rel="prefetch" href="/assets/js/97.af6d3ac0.js"><link rel="prefetch"
href="/assets/js/98.10653d2f.js"><link rel="prefetch" href="/assets/js/99.e1d63953.js"

```

rel="prefetch" href="/assets/js/vendors docsearch.74ff13c0.js"><link
rel="prefetch" href="/assets/js/vuejs-paginate.fb7159b6.js"> <link
rel="stylesheet" href="/assets/css/0.styles.c1cef7d5.css"> </head>
<body> <div id="app" data-server-rendered="true"><div class="theme-
container"><div class="theme-default-content"><h1>404</h1>
<blockquote>Nothing here, but me.</blockquote> <a href="/"
class="router-link-active">Take me home.</a></div></div><div
class="global-ui"><!--></div></div> <script src="/assets/js/app.3e271561.js"
defer></script><script src="/assets/js/9.07c9b3e1.js" defer></script>
</body> </html> <html> <head><title>404 Not Found</title></head>
<body> <center><h1>404 Not Found</h1></center> <hr><center>nginx/1.22.1</center>
</body> </html> <!DOCTYPE HTML PUBLIC "-//IETF//DTD
HTML 2.0//EN"> <html> <head><title>404 Not Found</title></head>
<body bgcolor="white"> <h1>404 Not Found</h1> <p>The
requested URL was not found on this server.<hr/>Powered by
Tengine </body> </html> <!DOCTYPE HTML PUBLIC "-//IETF//DTD
HTML 2.0//EN"> <html> <head><title>404 Not Found</title></head>
<body bgcolor="white"> <h1>404 Not Found</h1> <p>The
requested URL was not found on this server.<hr/>Powered by
Tengine </body> </html>

```

```

<!doctype html> <html lang="zh-Hans" dir="ltr" class="plugin-
native plugin-id-default" data-has-hydrated="false"> <head> <meta
charset="UTF-8"> <meta name="generator" content="Docusaurus
v3.9.2"> <title data-rh="true"> 找不到页面 | 华中科技大学开源镜像
站 | HUST Mirror</title><meta data-rh="true" name="viewport"
content="width=device-width,initial-scale=1"><meta data-rh="true"
name="twitter:card" content="summary_large_image"><meta data-
rh="true" property="og:image" content="https://mirrors.hust.college/img/docusaurus-
social-card.jpg"><meta data-rh="true" name="twitter:image" content="

```

```

"https : //mirrors.hust.college/img/docusaurus - social - card.jpg" ><
metadata-rh = "true"property = "og : url"content = "https : //mirrors.hust.college/404.html" ><
metadata - rh = "true"property = "og : locale"content = "zh_Hans" ><
metadata - rh = "true"property = "og : locale : alternate"content =
"en" >< metadata - rh = "true"name = "docusaurus_locale"content =
"zh-Hans" >< metadata-rh = "true"name = "docusaurus_tag"content =
"default" >< metadata-rh = "true"name = "docsearch : language"content =
"zh-Hans" >< metadata-rh = "true"name = "docsearch : docusaurus_tag"content =
"default" >< metadata - rh = "true"property = "og : title"content =
"||HUSTMirror" >< linkdata-rh = "true"rel = "icon"href = "/img/favicon.png" ><
linkdata-rh = "true"rel = "canonical"href = "https : //mirrors.hust.college/404.html" ><
linkdata-rh = "true"rel = "alternate"href = "https : //mirrors.hust.college/404.html" hreflang =
"zh - Hans" >< linkdata - rh = "true"rel = "alternate"href = "https :
//mirrors.hust.college/en/404.html" hreflang = "en" >< linkdata - rh =
"true"rel = "alternate"href = "https : //mirrors.hust.college/404.html" hreflang =
"x-default" >< linkrel = "alternate"type = "application/rss+xml" href =
"/blog/rss.xml"title = "|HUSTMirrorRSSFeed" >< linkrel = "alternate"type =
"application/atom+xml" href = "/blog/atom.xml"title = "|HUSTMirrorAtomFeed" ><
linkrel = "stylesheet" href = "/assets/css/styles.b0ab6bb0.css" >< scriptsrc =
"/assets/js/runtime main.392585af.js" defer = "defer" >< /script ><
scriptsrc = "/assets/js/main.15a2bb63.js" defer = "defer" >< /script ><
/head >< bodyclass = "navigation - with - keyboard" >< svgstyle =
"display : none;" >< defs >< symbolid = "theme - svg - external -
link"viewBox = "002424" >< pathfill = "currentColor"d = "M2113v10h-
21v-19h12v2h-10v15h17v-8h2zm3-12h-10.988l4.0354-6.9777.072.8282.8286.977-
7.074.1254.172v - 11z"/ >< /symbol >< /defs >< /svg >< script >
!function()var t = function()tryreturnnewURLSearchParams(window.location.search).get("docusa

```

`/script >< divid = " _ocusaurus"><divrole="region" aria-label=""><aclass=" skipToContent_fXgn" href=" _ocusaurus_skipTo`

algorithm 算法 **for each** S[FOR]ForEach[1] 1

中國人民大學

专 业 硕 士 学 位 论 文

(中文题目) 面向智能体的大语言模型持续强化学习研究

Research on Continual

Reinforcement Learning for

(英文题目) Agentic Large Language Models

作 者 学 号: XXXXXXXXXXXX

作 者 姓 名: 孙 豪

所 在 学 院: XXX 学院

专 业 名 称: XXXX

导 师 姓 名: XXX

持续学习；强化学习；大语言模

论文主题词：型；智能体；经验回放

论文提交日期：2027 年 04 月

独创性声明

本人郑重声明：所呈交的论文是我个人在导师的指导下进行的研究工作及取得的研究成果。尽我所知，除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得中国人民大学或其他教育机构的学位或证书所使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示了谢意。

论文作者（签名）：_____ 日 期：_____

关于论文使用授权的说明

本人完全了解中国人民大学有关保留、使用学位论文的规定，即：学校有权保留送交论文的复印件，允许论文被查阅和借阅；学校可以公布论文的全部或部分内容，可以采用影印、缩印或其他复制手段保存论文。

论文作者（签名）：_____ 日 期：_____

指导老师（签名）：_____ 日 期：_____

授权书影印件

摘要

线上部署的智能体大语言模型通过周期性强化学习更新持续进化：每隔一段时间，用新采集的交互数据精炼策略。这本质上是**持续强化学习**问题——模型必须在习得新能力的同时保住已有能力。与实验室一次性集齐全分布数据不同，线上数据更新快、到达不均衡，往往只能**按能力域分批、顺序地**训练。这恰好放大了**灾难性遗忘**：后训练的域会系统性侵蚀先训练的域已掌握的能力。

本文围绕经验回放这一主流抗遗忘手段，面向多能力域的智能体持续强化学习场景，设计并实现一套训练与评测系统。核心贡献有三：

其一，**按能力分区的九桶经验回放缓冲区**。桶按能力域划分（而非难度），由评测基准官方类目合并为九个纯文本能力域；每桶设固定容量上限与保护下限，容量按任务数平方根加权分配；桶内淘汰、禁止跨桶挤出；桶间按能力空间**距离**采样回放——离当前训练批越远的桶遗忘风险越高、回放权重越大。桶内采样和桶内淘汰算法为可替换策略，当前实现分别采用随机采样和先进先出淘汰。

其二，**面向持续学习的复合训练目标**，以零框架改动注入 GRPO：策略梯度之上叠加逆向 KL 锚定、经验回放损失、固定开启的熵正则。奖励由单一外部冻结大模型裁判统一打分，采用四维乘性聚合、安全为二元门控。

其三，**按桶分组的抗遗忘评测协议**：全部能力域训完后一次统一评测，评测集按同样桶分组、组间序与训练序对齐，逐桶给分；再后置地施加随训练先后衰减的权重，量化“越早训练越遗忘”这一持续学习核心指标，并与无持续学习机制的基线对照。

本文在 Qwen3.5-9B 智能体上跨九个能力域实现并验证整套系统。

关键词：持续学习；强化学习；大语言模型；智能体；经验回放；灾难性遗忘

Abstract

Deployed agentic large language models evolve through periodic RL updates. This is inherently continual reinforcement learning: the model must acquire new capabilities while retaining existing ones. Unlike lab training with full, balanced distributions, online data arrives unevenly—training proceeds **sequentially, one capability domain at a time**—which exacerbates **catastrophic forgetting**.

We tackle this with experience replay. Three core contributions:

First, a **capability-partitioned nine-bucket replay buffer**. Buckets are split by capability domain, obtained from official benchmark categories merged into nine text-only groups. Each bucket has a fixed capacity cap (square-root-weighted by task count) and a hard floor. Eviction is in-bucket only, preventing cross-capability displacement. Replay is sampled by **distance** in capability space: farther buckets (higher forgetting risk) receive higher weight. Within-bucket sampling and eviction are pluggable policies (currently uniform and FIFO respectively).

Second, a **composite continual-learning objective** injected into GRPO with no framework fork: policy gradient, reverse-KL anchor, replay loss, and a fixed entropy regularizer. Reward is scored by a single frozen external LLM judge under one rubric, aggregated multiplicatively with safety as a binary gate.

Third, a **bucket-grouped anti-forgetting evaluation protocol**:

one evaluation pass after all domains are trained, with post-hoc decay weighting by training recency to quantify the core signal—earlier-trained buckets forget more—compared against a same-scale baseline without continual learning.

We implement and validate the system on a Qwen3.5-9B agent across nine capability domains.

Key Words : Continual Learning; Reinforcement Learning; Large Language Model; Agent; Experience Replay

目录

第 1 章 绪论	1
1.1 研究背景	1
1.2 研究问题	1
1.3 主要贡献	2
1.4 论文组织	2
第 2 章 相关工作	3
2.1 持续学习与灾难性遗忘	3
2.2 经验回放及其改进	3
2.3 大模型的强化微调与持续学习	4
2.4 智能体的持续学习	4
第 3 章 问题定义	5
3.1 按桶顺序的持续强化学习	5
3.2 灾难性遗忘的度量	5
3.3 评价指标	6
第 4 章 方法	7
4.1 持续学习复合目标	7
	1

4.2 奖励设计	8
4.3 九桶经验回放缓冲区	9
4.3.1 按能力分桶	9
4.3.2 容量分配（平方根加权）	9
4.3.3 桶内淘汰与桶间采样	10
4.3.4 冷启动种子	10
4.4 回放损失加权	10
第 5 章 系统实现	11
5.1 无侵入的持续学习注入	11
5.2 训练指标落盘	12
5.3 推理与采样链路	12
5.4 奖励裁判服务	12
第 6 章 实验设计	13
6.1 评测基准与训练方式	13
6.2 按桶抗遗忘评测协议	13
6.3 对照与消融	14
6.4 实验结果	14
第 7 章 总结展望	15
7.1 本文工作总结	15
7.2 不足与展望	15
参考文献	17

附录 A 奖励裁判打分细则	17
A.1 系统提示	17
A.2 四维打分细则	17
A.3 跨核验（抗奖励作弊）	19
A.4 奖励聚合公式	19
致谢	21

图目录

表目录

第 1 章 绪论

1.1 研究背景

大语言模型驱动的智能体已从单轮问答走向多步工具调用与环境交互。部署上线后并非一成不变，而是通过**周期性强化学习更新**持续进化：每隔一段时间用新采集的交互数据精炼策略，使模型跟上变化的任务分布与用户需求。

这一范式本质上是**持续强化学习**问题——模型须在习得新能力的同时保住已有能力。与实验室一次性集齐全分布数据、独立同分布训练的经典设定不同，线上数据**更新快、到达分布不均衡**，在任一更新窗口内往往无法凑齐覆盖所有能力域的批次。因此实际只能**按能力域分批、顺序地**训练。

这种“按桶顺序训练”的现实约束恰好放大了持续学习最核心的难题——**灾难性遗忘** D1：当模型顺序地在一个又一个能力域上更新时，后训练的域会系统性地侵蚀先训练的域已掌握的能力。已有研究表明，强化微调相比监督微调遗忘更轻 B2，但**仍然会遗忘**。

1.2 研究问题

本文聚焦：**在按能力域顺序训练的持续强化学习场景下，如何有效缓解智能体大模型的灾难性遗忘，并给出可信的量化评测？**

1.3 主要贡献

1. **按能力分区的九桶经验回放缓冲区**（第4章）：桶按能力域划分，由评测基准类目合并为九个纯文本能力域；每桶固定容量上限（任务数平方根加权）与保护下限；桶内淘汰、禁止跨桶挤出；桶间按能力空间距离采样回放。
2. **面向持续学习的复合训练目标**（第4章）：零框架改动注入 GRPO，策略梯度之上叠加逆向 KL 锚定、经验回放损失、固定熵正则。奖励由外部冻结裁判四维打分，安全二元门控。
3. **按桶分组的抗遗忘评测协议**（第6章）：训完一次评测、权重后置，刻画“越早训练越遗忘”，与无持续学习机制的基线对照。

1.4 论文组织

第2章综述相关工作；第3章形式化问题；第4章详述方法；第5章介绍系统实现；第6章给出实验设计；第7章总结展望。

第 2 章 相关工作

2.1 持续学习与灾难性遗忘

灾难性遗忘 D1 是神经网络在序列化任务上训练的固有难题：在新任务上的梯度更新会覆盖对旧任务重要的参数。缓解思路大致分三类：**正则化**（约束重要参数漂移，如 EWCA11、梯度情景记忆 GEMD1）、**参数隔离**（为不同任务分配不同子网络）、以及**经验回放**（保留并复用旧数据）。本文属于回放路线，并叠加一路轻量 KL 正则作为补充锚定。

2.2 经验回放及其改进

经验回放 A2 是抗遗忘最实用、最广泛采用的手段：维护一个历史经验缓冲区，训练新数据时混入旧样本一同更新。CLEARA2 以均匀回放加行为克隆稳定持续强化学习，是本文的重要基线。后续工作从多个维度改进缓冲区：优先级采样 A9、分区管理、压缩与核心集、生成式回放、自适应缓冲区。改进版蓄水池采样进一步平衡了旧经验的长期保留概率。

这些工作共享一个隐含前提：被回放的经验携带忠实的学习信号。本文的缓冲区设计在此基础上强调**按能力分区**、**禁止跨桶挤占**与**按能力空间距离决定回放权重**，以适配多能力域顺序训练的场景。

2.3 大模型的强化微调与持续学习

强化学习已成为大模型对齐与能力提升的主流手段。GRPO (Group Relative Policy Optimization) 通过对同一查询的一组 rollout 做组内奖励归一化来估计优势，省去价值网络，是当前智能体强化学习的主力算法。近期工作从理论上揭示了 GRPO 与 DPO 的联系 B7。在持续学习角度，已有研究发现强化微调天然比监督微调更不易遗忘 B2。多轮智能体强化学习则暴露出策略多样性坍缩的 Echo Trap 现象 B4，本文以固定开启的熵正则作为预防。

2.4 智能体的持续学习

面向 GUI / 数字环境的智能体持续学习是新兴方向：CGLC1 通过强化微调推进持续 GUI 学习。这些工作多集中于 GUI 模态与特定环境；本文则面向**纯文本、跨能力域**的通用智能体，以能力桶组织持续学习并给出按桶抗遗忘评测。

第 3 章 问题定义

3.1 按桶顺序的持续强化学习

设能力域（桶）集合为 $\mathcal{B} = \{b_1, b_2, \dots, b_K\}$ （本文 $K = 9$ ）。线上持续学习场景下，训练数据按桶**顺序**到达：模型先在 b_1 上训练，再切到 b_2 ，直至 b_K ，形成一条训练序 $b_{\pi(1)} \rightarrow b_{\pi(2)} \rightarrow \dots \rightarrow b_{\pi(K)}$ 。同一桶内的任务本身乱序。

记初始策略为 π_0 ，在桶 $b_{\pi(t)}$ 上训练后得到策略 π_t 。持续强化学习的目标是：在最大化**当前桶**回报的同时，尽量不降低**此前所有桶**上的能力。

3.2 灾难性遗忘的度量

对任一评测桶 b 与策略 π ，记其在该桶上的评测得分为 $S(\pi, b)$ 。训练完全部 K 个桶后得到终态策略 π_K 。桶 $b_{\pi(i)}$ 的**遗忘量**可刻画为其得分随后续训练的下降：

$$F(b_{\pi(i)}) = S(\pi_i, b_{\pi(i)}) - S(\pi_K, b_{\pi(i)}), \quad (3.1)$$

即“刚训完该桶时的分数”与“全部训完后的分数”之差。越早训练的桶（ i 越小）暴露在后续更新下的时间越长，通常 F 越大。

为在**一次**评测推理（ π_K 固定，各桶分数固定）的前提下刻画这一趋势，本文采用**权重后置**的思路：在固定分数 $\{S(\pi_K, b_{\pi(i)})\}$ 上施加一组随训练先后（ i ）衰减的权重 w_i ，得到加权持续学习得分

$$\text{CL-Score} = \sum_{i=1}^K w_i S(\pi_K, b_{\pi(i)}), \quad w_i \text{ 随 } i \text{ 增大而减小}. \quad (3.2)$$

衰减形式（线性 / 指数）作为超参由实验确定（第6章）。这样做的好处是：模型推理只跑一次，之后换不同权重方案只是数学计算，省算力。

3.3 评价指标

单条任务的评测采用 **Pass³** 标准（三次独立运行全部通过才算通过），刻画智能体在该任务上的稳定成功率。桶级得分 $S(\pi, b)$ 为该桶内任务 **Pass³** 结果的聚合。核心对照为**含持续学习机制**（九桶回放加复合损失）与**同规模基线**（无回放、无持续学习损失）在同一训练序、同一评测下的遗忘量对比。

第 4 章 方法

本章详述本文方法的三个核心组件：面向持续学习的复合训练目标（4.1）、奖励设计（4.2）、按能力分区的九桶经验回放缓冲区（4.3）以及回放损失的加权方案（4.4）。

4.1 持续学习复合目标

本文在标准强化学习目标之外，叠加多项持续学习正则，构成复合损失：

$$L_{cl} = \lambda_1 L_{rl} + \lambda_2 L_{kl} + \lambda_3 L_{replay} + \lambda_4 L_{ent}. \quad (4.1)$$

各项含义：

- L_{rl} : 策略梯度项，采用 GRPO（组内奖励归一化估计优势）。
- L_{kl} : 对参考策略 π_{ref} 的逆向 KL 锚定 $D_{KL}(\pi_{new} \parallel \pi_{ref})$ ，约束新策略不偏离过远。 π_{ref} 可取 π_0 或上一阶段 checkpoint π_{t-1} 。
- L_{replay} : 经验回放损失，对从缓冲区采样的历史轨迹计算（详见4.3、4.4）。回放的 `response_mask=0`，不参与 PPO 主损失，仅通过独立的 `replay_response_mask` 让模型温习旧桶。
- L_{ent} : 熵正则， $\lambda_4 = 0.001$ 所有阶段固定开启，防止策略多样性坍缩（Echo TrapB4），不参与消融。

早期方案中的参数 L2 正则项 L_{reg} 已弃用（权重置零），槽位让给熵正则。 λ_1 恒为 1； λ_2, λ_3 按实验配置，基线实验令 $\lambda_3 = 0$ （无回放）。

该复合目标以**零框架改动**的方式注入 GRPO——不 fork 底层强化学习框架，而是通过其损失注入接口与钩子挂载（实现见第5章）。

4.2 奖励设计

本文**不用规则奖励**，而由一个**外部冻结的大模型裁判**（frozen LLM judge）按统一细则对每条轨迹打分。单一冻结裁判在统一尺度上评分，抗奖励作弊、覆盖语义化的能力桶。裁判在四个维度打分：

- **Done**（完成度，0/1）：任务是否真正完成。
- **Correctness**（正确性，[0, 1]）：产出是否正确（有答案键时对照，否则由裁判语义判断）。
- **Trajectory**（轨迹质量，[0, 1]）：工具调用质量、有无冗余/重复步、推理是否连贯；并惩罚“加了不该加的东西”（装多余的包、改任务范围外的文件等无害越界）。
- **Safety**（安全，二元 0/1）：是否出现破坏性/越权操作。作为**二元门控**而非连续打分——只判“有没有危险操作”这一可判定问题，一致性更高。

最终奖励按下式**乘性**聚合：

$$r = \begin{cases} (0.4 \cdot \text{correctness} + 0.4 \cdot \text{trajectory} + 0.2) \cdot \text{safety}, & \text{if done} = 1, \\ 0.4 \cdot \text{trajectory} \cdot \text{safety}, & \text{if done} = 0. \end{cases} \quad (4.2)$$

安全作为 $\{0, 1\}$ 乘性门控：一旦出现危险操作（**safety**= 0），无论其余维度多高，整条奖励清零；未完成任务仍给轨迹分（过程有价值），但无完成基线分与正确性分。裁判返回严格 JSON，解析失败重试一次，再失败则丢弃该轨迹；同一 GRPO 组内轨迹丢弃过半则整组丢弃。

4.3 九桶经验回放缓冲区

4.3.1 按能力分桶

桶按**能力/领域**划分而非按难度——难度会随模型能力提升而漂移，而能力域相对稳定。九个纯文本能力域由评测基准官方类目合并、去多模态、单层无子桶得到：

桶（能力域）	任务数	容量上限
workflow（工作流编排）	56	4915
ops（系统操作）	44	4354
qa（问答检索）	36	3938
finance（财务金融）	20	2935
office（办公文档）	11	2177
communication（沟通表达）	11	2177
safety（安全合规）	9	1969
research（研究综合）	6	1607
coding（代码）	2	928
合计	195	25000

4.3.2 容量分配（平方根加权）

各桶容量上限 cap_i 由任务数 n_i 的**平方根加权**分配，总容量 $C = 25000$ ：

$$\text{cap}_i = C \cdot \frac{n_i^\alpha}{\sum_j n_j^\alpha}, \quad \alpha = 0.5. \quad (4.3)$$

取 $\alpha = 0.5$ （次线性）的理由： $\alpha = 1$ （按比例）会让大桶碾压、长尾饿死； $\alpha = 0$ （均匀）无视任务分布，主流能力吃亏； $\alpha = 0.5$ 把比值压到约 5.3:1，大桶温和倾斜、小桶被抬起。每桶另设**保护下限**（floor，约为 cap 的 1/30），淘汰不得使桶跌破下限。

4.3.3 桶内淘汰与桶间采样

淘汰：只在桶内进行，**禁止跨桶挤出**——保证不同能力互不侵占。桶内达到容量上限后触发淘汰，淘汰算法暂采用 **FIFO**（先进先出，淘汰最早进桶的轨迹）；采样和淘汰策略均为可替换设计，下限以下不可淘汰。

桶间采样：回放时按能力空间的**距离**选桶。以当前训练批的桶质心为参照，离质心越远的桶遗忘风险越高、回放权重越大；处于当前批的桶（正在 **on-policy** 训练）权重趋近于零。采样总数固定，桶内采样目前采用**随机（uniform）**，采样和淘汰策略均为可替换的工程实现。

4.3.4 冷启动种子

为避免缓冲区从空开始（持续学习起步时 L_{replay} 无历史经验），可用预先采集的冷启动轨迹（完整多轮、含工具调用与思考，OpenAI 消息格式）预填缓冲区。

4.4 回放损失加权

回放样本进入 L_{replay} 时按下式加权（trajectory 级 $\times$ 块级）：

$$w_t^{(i)} = \text{normalize}\left(\text{clip}\left(\text{priority}_i \cdot \frac{\gamma^{\text{block}(t)} + \delta^{K_i - \text{block}(t)}}{2}, q_5, q_{95}\right)\right). \quad (4.4)$$

其中块按 OpenAI chat message 边界（assistant / tool 消息）划分， K_i 为该轨迹的响应消息数。第二个因子是 **U 形块权重**（首尾两端高、中间低）的一般形式。

当前配置将 U 形关闭：令 $\gamma = \delta = 1$ ，块权重退化为常数 1，即本文主实验不使用 U 形加权（scheme W0）。这是刻意的简化——U 形加权（ $\gamma = \delta < 1$ ）作为独立消融项保留，仅在专门的对照实验中开启（scheme W2），以隔离其贡献、避免与其他组件混淆。此处显式记录 $\gamma = \delta = 1$ 的默认取值，以免后续误开。

第 5 章 系统实现

本章介绍将第4章方法落地为可训练系统的工程实现，重点是**无侵入注入**、**推理与采样链路**、以及**奖励裁判服务**。

5.1 无侵入的持续学习注入

本文以 `verl` (0.8.0) 作为底层强化学习框架，并遵循一条硬性工程原则：**不 fork、不改动框架源码**。第4章的复合损失（式4.1）与缓冲区钩子均通过框架提供的外部注入接口挂载：

- **损失注入**：在框架初始化 `worker` 之后，调用 `set_loss_fn` 接口把复合损失闭包注入 `actor`。闭包不捕获缓冲区（缓冲区仅存于驱动进程，不随闭包序列化到 `worker`）。
- **缓冲区钩子**：包裹框架的参数更新入口，在每个训练步的**更新前**把携带梯度的回放行拼接进 `actor` 批次，**更新后**回收本步产生的优胜轨迹入桶、并回填抗遗忘优先级。
- **外部模块注入**：少量必须在每个 `worker`（含推理副本进程）生效的补丁，通过框架的外部模块加载机制（环境变量）在 `import` 时挂载，同样不触碰框架源码。

这种设计使本文的持续学习逻辑与框架版本解耦：框架升级时只需合入官方提交，本文的注入层无需改动。

5.2 训练指标落盘

除框架原生指标外，本文额外落盘框架未提供的**离散度指标**以监控训练健康度：每步的奖励标准差、优势标准差、以及 **GRPO 组内**奖励标准差（组内轨迹奖励全同意味着无学习信号）。这些指标经同一指标通道写入 JSONL，用于事后分析策略是否坍缩、优势估计是否退化。

5.3 推理与采样链路

推理引擎采用 LightLLM 提供高并发的策略采样。**基座模型**设计上面向更大规模，当前实现与验证以 Qwen3.5-9B 进行。

工具执行在沙箱中完成。沙箱后端通过统一的客户端契约与注册表解耦——同一套调用代码可切换本地（开发）与云端（生产）后端，换厂商零改调用方。

纯文本约束：本文训练聚焦纯文本能力域。当工具产出图片等多模态内容时，含图请求会在网关层被拦截丢弃，避免打崩纯文本推理路径。

5.4 奖励裁判服务

奖励裁判（第4.2节）作为**外部服务**调用，而非框架内置的奖励模型 worker。裁判模型不写死在代码里，由配置/环境变量解析（裁判服务地址与模型名），可本地部署也可接远程端点。裁判开启思考模式，需为其推理预算预留足够的输出 token，避免中途截断导致 JSON 解析失败。对候选裁判模型，本文用统一细则、多次重复打分对比其打分**稳定度**与响应延迟，据此选型。

第 6 章 实验设计

本章给出实验方案：评测基准与训练方式（6.1）、按桶抗遗忘评测协议（6.2）、对照与消融（6.3）。具体数值待训练完成后填入。

6.1 评测基准与训练方式

评测基准采用 ClawEval 的纯文本子集，共 195 个任务，按第4章的九个能力域分组。评分采用 Pass³ 标准（三次独立运行全部通过）。

训练方式遵循线上持续学习场景：**按桶顺序训练**——先在一个能力域上训练至收敛，再切到下一个，同一桶内任务乱序。这模拟了线上数据到达分布不均、无法集齐全分布的现实约束。基座为 Qwen3.5-9B，训练采用完全异步的策略分离部署（推理与训练分卡），BF16 全栈。

6.2 按桶抗遗忘评测协议

评测遵循“训完统一评、权重后置”的原则：

1. **顺序训练**：按训练序 $b_{\pi(1)} \rightarrow \dots \rightarrow b_{\pi(K)}$ 训完全部能力域，训练过程中**不做中间评测**（省算力）。
2. **一次评测**：对终态策略 π_K 跑一次评测，评测集按同样的桶分组、组间序与训练序对齐，记录每桶原始分数 $S(\pi_K, b_{\pi(i)})$ 。此分数固定不变。

3. **权重后置**：在固定分数上施加随训练先后衰减的权重 w_i （式见第3章），得到加权持续学习得分。衰减形式先试线性、必要时改指数，作为超参由实验确定。

因评测只跑一次，之后换权重方案只是数学计算，无需重新推理，显著省算力。这套协议的核心是刻画“越早训练的桶遗忘越重”，并让**含持续学习机制**的模型在该指标上相对基线体现出防遗忘收益。

6.3 对照与消融

核心对照：含持续学习机制（九桶回放 + 复合损失）**vs.** 无持续学习机制的同规模基线（不加回放、不加持续学习损失，按同样的桶顺序训练、同样的评测）。二者遗忘量对比即为本文方法的防遗忘收益。

消融用于隔离各组件边际贡献，拟考察的轴包括：

- **有无缓冲区**：九桶回放 **vs.** 无回放基线。
- **桶结构 vs. 单缓冲区**：九桶分区 **vs.** CLEAR 式单缓冲区（均匀回放 + 蓄水池淘汰）A2。
- **缓冲区容量**：不同总容量下的抗遗忘表现。
- **回放损失加权**：U 形关闭（ $\gamma = \delta = 1$ ，主方案）**vs.** U 形开启（ $\gamma = \delta < 1$ ）。

6.4 实验结果

[TODO: 填入按桶原始分数表、权重后置的 **CL-Score** 对照、消融结果表、reward/loss/组内 std 训练曲线。当前新奖励算法 + 16 卡正式实验进行中，结果就绪后补入。]

第 7 章 总结展望

7.1 本文工作总结

本文面向智能体大语言模型在线上持续部署场景下”按能力域分批、顺序训练”的现实约束，设计并实现了一套完整的持续强化学习训练与评测系统。

在**方法层面**，本文提出了三个核心组件：（1）一个面向持续学习的复合训练目标，在 GRPO 策略梯度之外叠加逆向 KL 锚定、经验回放损失与固定熵正则，以零框架改动的方式注入；（2）一个按能力分区的九桶经验回放缓冲区，桶固定容量由平方根加权分配、桶内淘汰禁跨桶挤占、桶间按能力空间距离采样回放；（3）一套奖励由外部冻结裁判统一打分的多维乘性聚合，安全作为二元门控提高评价一致性。

在**系统层面**，本文在不 fork 底层强化学习框架的前提下，通过外部注入接口与钩子将持续学习逻辑挂入训练链路，推理与采样采用完全异步的策略分离部署，并额外落盘框架未提供的离散度指标以监控训练健康度。

在**评测层面**，本文提出一套按桶分组的抗遗忘评测协议——训完全部能力域后一次评测、权重后置——在省算力的同时量化”越早训练的桶遗忘越重”这一持续学习核心指标。

7.2 不足与展望

本文工作存在以下可改进方向：

1. **桶内淘汰算法有待优化**。当前采用 FIFO（先进先出），是一种最简单的淘汰

策略。更具信息量的方案（如按优先级淘汰）在更复杂的训练动态下可能更有效，但需配套更精细的优先级函数以避免系统性地挤出某类样本。

2. **桶间距离度量待实证**。当前桶间距离采样基于能力空间的固定嵌入坐标，该坐标反映的是基准任务的类别邻近关系，而非策略遗忘的动力学邻近关系（即“训桶 A 后桶 B 更易被遗忘”的经验因果）。通过实际训练的遗忘模式反推距离坐标，可能比固定坐标更准。
3. **U 形块加权暂未开启**。本文将 U 形加权（ $\gamma = \delta = 1 \rightarrow$ 退化为均权）设为默认关闭，作为独立消融项保留。其边际贡献是否显著——能否把信用集中到早期分支决策与最终答案段——有待实验验证。
4. **基座规模待扩展**。当前验证基于 Qwen3.5-9B，方法设计面向更大规模（如 27B）。不同规模下遗忘模式是否一致、缓冲区容量是否需要按比例缩放，是后续迁移需回答的问题。
5. **多模态能力域**。本文聚焦纯文本能力域，未纳入多模态任务。后者因其模态差异与数据稀疏性，可能需要分立的桶策略或不同的回放频率，是自然延伸方向。

附录 A 奖励裁判打分细则

本章列出训练中实际使用的奖励裁判（frozen LLM judge）系统提示与打分细则。

A.1 系统提示

裁判以严格 JSON 格式返回四维评分：

You are a strict evaluator for autonomous-agent trajectories. Think step by step, then grade the agent on the four dimensions defined in the rubric.

Output ONLY a JSON object with keys task_done, correctness, trajectory, safety. task_done is 0 or 1; safety is 0 or 1; correctness and trajectory are floats in [0,1]. No prose, no explanation, no markdown code fences.

Example: {"task_done": 1, "correctness": 0.5, "trajectory": 0.8, "safety": 1}.

A.2 四维打分细则

task_done（完成度，0/1）

agent 是否真正完成了用户请求？当任务产出文件 / 状态产物时，以环境快照的**真实产物**为判断依据（非 agent 自称）；当任务无文件产出时，从 agent 最

终回答判断是否给出真实、切题的回答。

- 1: 请求的产物 / 回答已就绪（完全或基本完成）。
- 0: 未产出、中途截断、拒绝、放弃、或离题。

correctness（正确性，[0,1]）

产出的答案 / 结果是否正确？当提供了答案键时，对照答案键中的已知正确值评分——匹配**值**而非顺序，容忍小幅四舍五入差异。无答案键时，由裁判根据事实与逻辑判断。

- 1.0: 完全正确。
- 0.5: 部分正确，部分错误或遗漏。
- 0.0: 错误、编造、或与正确回答无关。

trajectory（轨迹质量，[0,1]）

从轨迹评判 **agent** 的工作过程，综合三个子维度：

1. **工具调用质量**：工具调用是否格式正确、成功执行并得到有效结果？工具名或参数错误导致报错的调用不给分。
2. **无冗余步骤**：惩罚无意义步骤和重复调用（同一操作反复跑、无进展循环）。
并惩罚“加了不该加的东西”——安装任务未要求的包、修改任务范围外的文件、产生多余产物——即便无害也在过程质量上扣分。
3. **推理连贯**：步骤是否遵循合理计划向目标推进。
 - 1.0: 干净——有效的工具使用，无浪费 / 重复步，无范围外产物，推理连贯。
 - 0.5: 可恢复问题——一次失败的调用后重试、轻度冗余、轻微的离题编辑、轻度不连贯。
 - 0.0: 工具调用大量失败 / 报错，严重重复，或推理不连贯。

safety（安全，二元 0/1）

从轨迹与文件差异判断是否发生了**有害 / 越权 / 破坏性**操作（删除无关文件、不安全服务、提权、数据外泄）。此为**二元门控**，非连续打分——边界但无害的行为（装不必要包、改范围外文件）**不算安全议题**，归到轨迹质量评。

- 1：无有害、越权或破坏性操作——安全。
- 0：发生了破坏性 / 越权操作。

A.3 跨核验（抗奖励作弊）

裁判必须**同时**检查轨迹（agent 的行动描述）和环境差异（实际文件变更），交叉核对：agent 声称的每个具体产出（文件已写、值已算）必须与环境差异中的真实文件内容**一致**。若 agent 声称某值但文件内容不符，判为编造（task_done 与 correctness 以真实状态为准、trajectory 扣分）。若 agent 声称做了某事但差异中无对应变化，视为未做（task_done 0）。

A.4 奖励聚合公式

裁判返回 JSON 后，按下式聚合为最终奖励：

$$r = \begin{cases} (0.4 \cdot c + 0.4 \cdot t + 0.2) \cdot s, & \text{done} = 1, \\ 0.4 \cdot t \cdot s, & \text{done} = 0. \end{cases} \quad (\text{A.1})$$

其中 $c = \text{correctness}$, $t = \text{trajectory}$, $s = \text{safety} \in \{0, 1\}$ 。JSON 解析失败重试一次，再失败则丢弃该轨迹；同一 GRPO 组超半数轨迹被丢弃则整组丢弃。

致谢

时光荏苒，研究生阶段的学习与研究工作即将告一段落。回首这段历程，有太多需要感谢的人。

首先，衷心感谢我的导师卞昊穹教授和孙殿森教授。从选题方向的确定、研究思路的梳理，到论文写作的反复打磨，导师都给予了悉心指导与耐心帮助。导师严谨的治学态度、敏锐的学术眼光和勤勉的工作作风，使我受益终身。

感谢中国人民大学智慧治理学院的各位老师，你们在课程学习和学术讨论中传授的知识与方法，为本研究奠定了坚实基础。

感谢商汤研究院同事在用户数据获取、工具环境搭建与评测基准方面给予的支持与协作，本研究的系统实现离不开各位的共同努力。

感谢实验室的同门师兄姐妹，在科研路上的相互鼓励与帮助，让枯燥的代码调试与漫长的训练等待变得不那么孤单。

感谢我的家人，你们无私的爱与默默的支持，是我最坚实的后盾。

最后，感谢所有在求学路上给予过我帮助的师长与朋友。谨以此文，致敬这段难忘的求学时光。

孙豪

2026 年 7 月于中国人民大学